- solr
- lucene
 - 倒排索引
 - 。 实际举例
 - o lucene API 介绍
 - 创建索引
 - 新建 maven 项目,添加依赖
 - 创建测试类,添加以下代码
 - 查看索引
 - 运行 luke
 - 查看文档
 - 指定分词器,并测试分词
 - 查询测试
 - 从索引查询
- solr 安装
 - o 解压 solr
 - o 启动 solr
 - o 浏览器访问 solr 控制台
- 创建 core
 - 复制默认配置
 - o 创建名为 pd 的 core
- 中文分词测试
 - 。 中文分词工具 ik-analyzer
 - 使用 ik-analyzer 对中文进行分词测试
 - 。 设置停止词
- 准备 mysql 数据库数据
- 从 mysql 导入商品数据
 - 。 设置字段
 - 。 Copy Field 副本字段
 - o Data Import Handler 配置
 - 。 导入数据
 - 查询测试
 - 在复制字段 _text_ 中查找 电脑
 - 在标题中查找 电脑
 - 用双引号查找完整词 "笔记本"
 - 搜索 +lenovo +电脑
 - 搜索 +lenovo -电脑
 - 统计 cid
 - 价格范围
 - 多字段统计

- 拼多商城实现商品的全文检索
 - 修改 hosts 文件, 添加 www.pd.com 映射
 - o eclipse 导入 pd-web 项目
 - 修改数据库连接配置
 - 启动项目, 访问 www.pd.com
 - 商品检索调用分析
 - o pom.xml 添加 solr 和 lombok 依赖
 - o application.yml 添加 solr 连接信息
 - o Item 实体类
 - SearchService 业务接口
 - SearchServiceImpl 业务实现类
 - SearchController 控制器

solr

Solr是一个高性能,<mark>基于Lucene</mark>的全文搜索服务器。同时对其进行了扩展,提供了比Lucene更为丰富的查询语言,同时实现了可配置、可扩展,并对查询性能进行了优化,并且提供了一个完善的功能管理界面,是一款非常优秀的全文搜索引擎。

lucene

Lucene是apache jakarta项目的一个子项目,是一个开放源代码的全文检索引擎开发工具包,但它不是一个完整的全文检索引擎,而是一个全文检索引擎的架构,提供了完整的查询引擎和索引引擎,部分文本分析引擎。Lucene的目的是为软件开发人员提供一个简单易用的工具包,以方便的在目标系统中实现全文检索的功能,或者是以此为基础建立起完整的全文检索引擎。

倒排索引

我们一般情况下,先找到文档,再在文档中找出包含的词;



倒排索引则是这个过程反过来,用词,来找出它出现的文档.



实际举例

文档编号	文档内容
1	全文检索引擎工具包
2	全文检索引擎的架构
3	查询引擎和索引引擎

分词结果

文档编号	分词结果集
1	{全文,检索,引擎,工具,包}
2	{全文,检索,引擎,的,架构}
3	{查询,引擎,和,索引,引擎}

倒排索引

编号	单词	文档编号列表
1	全文	1,2
2	检索	1,2
3	引擎	1,2,3
4	工具	1
5	包	1
6	架构	2
7	查询	3
8	索引	3

lucene API 介绍

创建索引

新建 maven 项目,添加依赖

```
project xmlns="http://maven.apache.org/POM/4.0.0"
    xmlns:xsi="http://www.w3.org/2001/XMLSchema-instance"
    xsi:schemaLocation="http://maven.apache.org/POM/4.0.0
http://maven.apache.org/xsd/maven-4.0.0.xsd">
    <modelVersion>4.0.0</modelVersion>
    <groupId>cn.tedu
    <artifactId>lucene-demo</artifactId>
    <version>0.0.1-SNAPSHOT</version>
    <name>luceme-demo</name>
    <dependencies>
        <dependency>
            <groupId>org.apache.lucene</groupId>
            <artifactId>lucene-core</artifactId>
            <version>8.1.1</version>
        </dependency>
        <dependency>
            <groupId>junit
            <artifactId>junit</artifactId>
            <version>4.12</version>
        </dependency>
        <dependency>
            <groupId>org.apache.lucene</groupId>
            <artifactId>lucene-analyzers-smartcn</artifactId>
            <version>8.1.1</version>
        </dependency>
    </dependencies>
</project>
```

创建测试类,添加以下代码

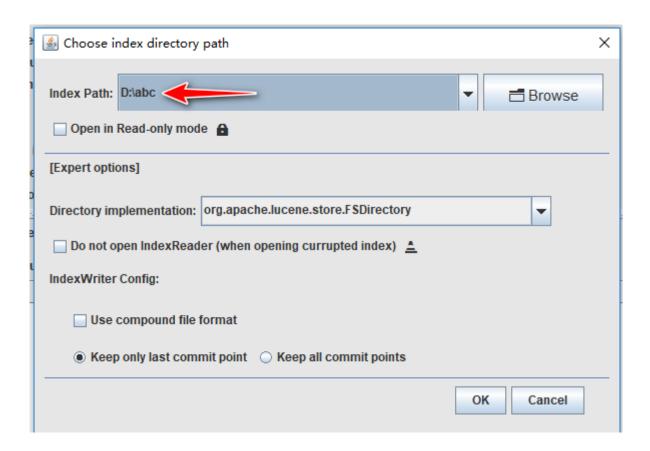
```
package test;
import java.io.File;
import org.apache.lucene.analysis.cn.smart.SmartChineseAnalyzer;
import org.apache.lucene.document.Document;
import org.apache.lucene.document.Field.Store;
import org.apache.lucene.document.LongPoint;
import org.apache.lucene.document.StoredField;
import org.apache.lucene.document.TextField;
import org.apache.lucene.index.IndexWriter;
import org.apache.lucene.index.IndexWriterConfig;
import org.apache.lucene.store.FSDirectory;
import org.junit.Test;
```

```
public class Test1 {
   String[] a = {
           "3,华为 - 华为电脑,爆款",
           "4,华为手机,旗舰",
           "5, 联想 - Thinkpad, 商务本",
           "6, 联想手机, 自拍神器"
   };
   @Test
   public void test1() throws Exception {
       //存储索引文件的路径
       File path = new File("d:/abc/");
       FSDirectory d = FSDirectory.open(path.toPath());
       //Lucene提供的中文分词器
       SmartChineseAnalyzer analyzer = new SmartChineseAnalyzer();
       //通过配置对象来指定分词器
       IndexWriterConfig cfg = new IndexWriterConfig(analyzer);
       //索引输出工具
       IndexWriter writer = new IndexWriter(d, cfg);
       for (int i = 0; i < a.length; i++) {</pre>
           String[] strs = a[i].split(",");
           //创建文档,文档中包含的是要索引的字段
           Document doc = new Document();
           doc.add(new LongPoint("id", Long.parseLong(strs[0])));
           doc.add(new StoredField("id", Long.parseLong(strs[0])));
           doc.add(new TextField("title", strs[1], Store.YES));
           doc.add(new TextField("sellPoint", strs[2], Store.YES));
           //将文档写入磁盘索引文件
          writer.addDocument(doc);
       writer.close();
   }
```

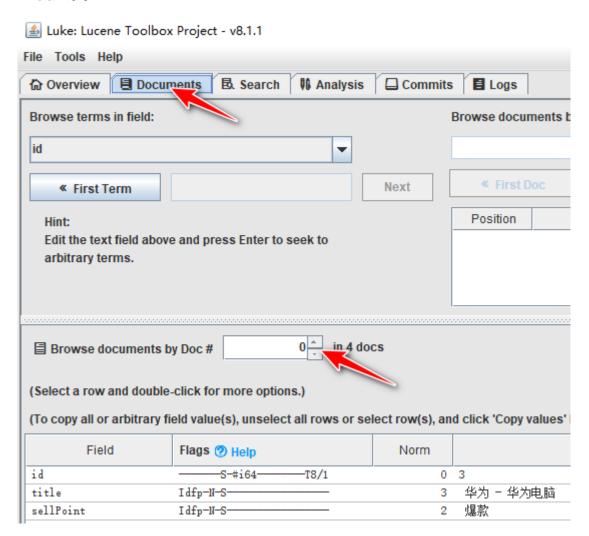
查看索引

运行 luke

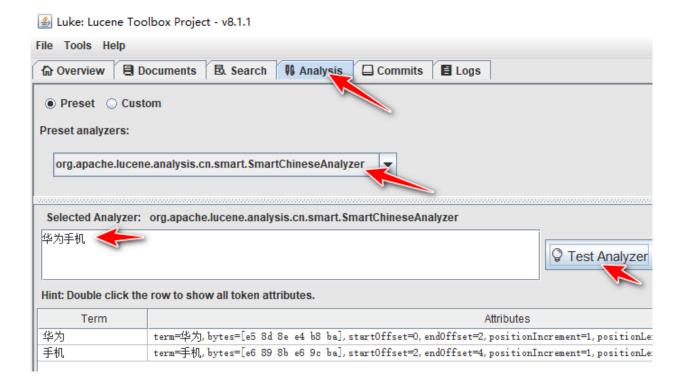
运行lucene 8.1.1中的luke应用程序,指定索引的存放目录



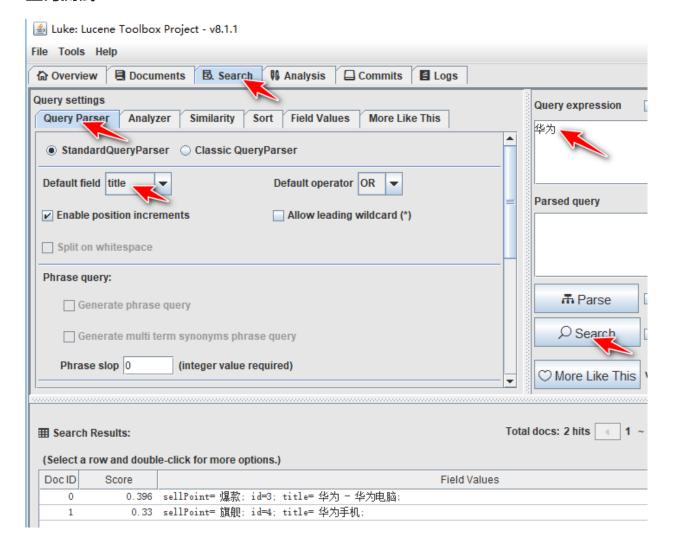
查看文档



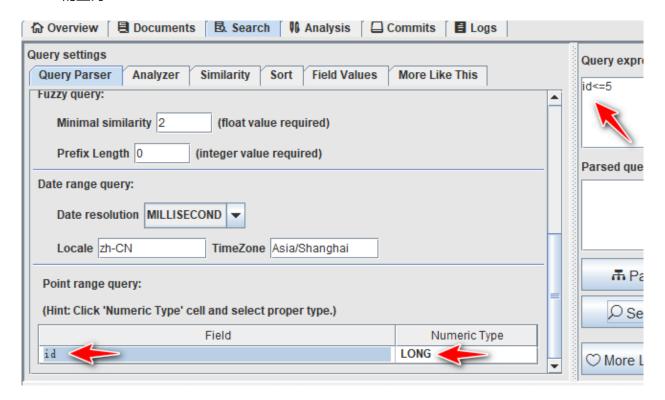
指定分词器,并测试分词



查询测试



• id的查询



从索引查询

在测试类中添加 test2() 测试方法

```
package test;
import java.io.File;
import org.apache.lucene.analysis.cn.smart.SmartChineseAnalyzer;
import org.apache.lucene.document.Document;
import org.apache.lucene.document.Field.Store;
import org.apache.lucene.document.LongPoint;
import org.apache.lucene.document.StoredField;
import org.apache.lucene.document.TextField;
import org.apache.lucene.index.DirectoryReader;
import org.apache.lucene.index.IndexWriter;
import org.apache.lucene.index.IndexWriterConfig;
import org.apache.lucene.index.Term;
import org.apache.lucene.search.IndexSearcher;
import org.apache.lucene.search.ScoreDoc;
import org.apache.lucene.search.TermQuery;
import org.apache.lucene.search.TopDocs;
import org.apache.lucene.store.FSDirectory;
import org.junit.Test;
public class Test1 {
    String[] a = {
            "3,华为 - 华为电脑,爆款",
            "4,华为手机,旗舰",
            "5, 联想 - Thinkpad, 商务本",
            "6, 联想手机, 自拍神器"
```

```
};
@Test
public void test1() throws Exception {
    //存储索引文件的路径
   File path = new File("d:/abc/");
   FSDirectory d = FSDirectory.open(path.toPath());
    //Lucene提供的中文分词器
   SmartChineseAnalyzer analyzer = new SmartChineseAnalyzer();
    //通过配置对象来指定分词器
   IndexWriterConfig cfg = new IndexWriterConfig(analyzer);
    //索引输出工具
   IndexWriter writer = new IndexWriter(d, cfg);
   for (int i = 0; i < a.length; i++) {</pre>
       String[] strs = a[i].split(",");
       //创建文档,文档中包含的是要索引的字段
       Document doc = new Document();
       doc.add(new LongPoint("id", Long.parseLong(strs[0])));
       doc.add(new StoredField("id", Long.parseLong(strs[0])));
       doc.add(new TextField("title", strs[1], Store.YES));
       doc.add(new TextField("sellPoint", strs[2], Store.YES));
       //将文档写入磁盘索引文件
       writer.addDocument(doc);
   writer.close();
}
@Test
public void test2() throws Exception {
    //索引数据的保存目录
   File path = new File("d:/abc");
   FSDirectory d = FSDirectory.open(path.toPath());
    //创建搜索工具对象
   DirectoryReader reader = DirectoryReader.open(d);
    IndexSearcher searcher = new IndexSearcher(reader);
   //关键词搜索器,我们搜索 "title:华为"
   TermQuery q = new TermQuery(new Term("title", "华为"));
    //执行查询,并返回前20条数据
    TopDocs docs = searcher.search(q, 20);
    //遍历查询到的结果文档并显示
    for (ScoreDoc scoreDoc : docs.scoreDocs) {
       Document doc = searcher.doc(scoreDoc.doc);
       System.out.println(doc.get("id"));
       System.out.println(doc.get("title"));
       System.out.println(doc.get("sellPoint"));
       System.out.println("----");
}
```

}

solr 安装

下面我们来安装 solr 服务器

解压 solr

```
cd /usr/local

# 上传 solr-8.1.1.tgz 到 /usr/local 目录

# 并解压缩
tar -xzf solr-8.1.1.tgz
```

启动 solr

```
cd /usr/local/solr-8.1.1

# 不建议使用管理员启动 solr,加 -force 强制启动
bin/solr start -force

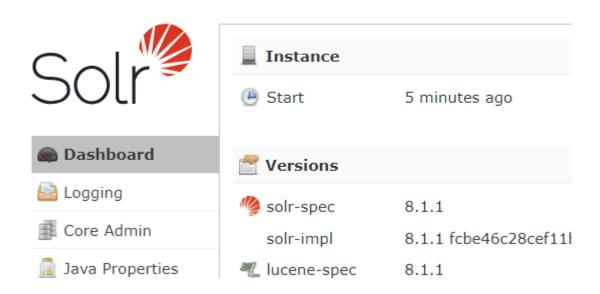
# 开放 8983 端口
firewall-cmd --zone=public --add-port=8983/tcp --permanent
firewall-cmd --reload
```

浏览器访问 solr 控制台

http://192.168.64.170:8983

• 注意修改地址





创建 core

数据库中 pd_item 表中的商品数据, 在 solr 中保存索引数据, 一类数据, 在 solr 中创建一个 core 保 存索引数据

创建一个名为 pd 的 core, 首先要准备以下目录结构:

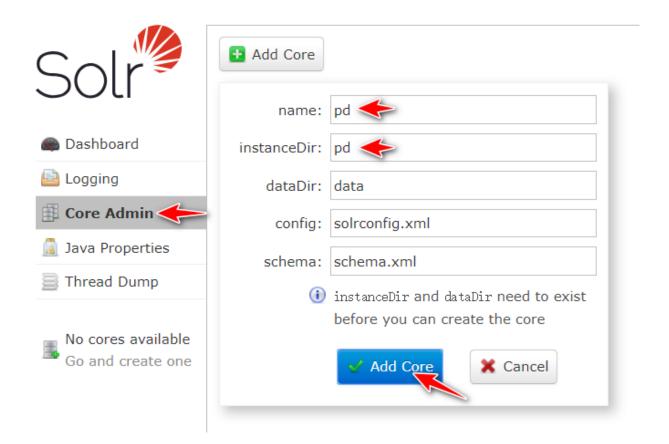
```
# solr目录/server/solr/
# pd/
                 conf/
                  data/
mkdir server/solr/pd
mkdir server/solr/pd/conf
mkdir server/solr/pd/data
```

conf 目录是 core 的配置目录, 存储一组配置文件, 我们以默认配置为基础, 后续逐步修改

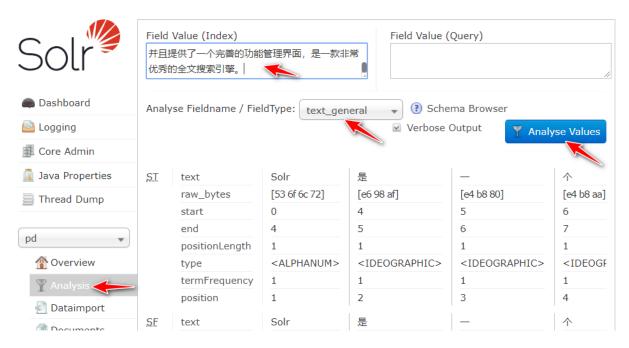
复制默认配置

```
cp -r server/solr/configsets/_default/conf server/solr/pd
```

创建名为 pd 的 core



中文分词测试



填入以下文本, 观察分词结果:

Solr是一个高性能,采用Java5开发,基于Lucene的全文搜索服务器。同时对其进行了扩展,提供了比Lucene 更为丰富的查询语言,同时实现了可配置、可扩展并对查询性能进行了优化,并且提供了一个完善的功能管理界面,是一款非常优秀的全文搜索引擎。

中文分词工具 - ik-analyzer

https://github.com/magese/ik-analyzer-solr

简介

适配最新版本solr 7&8;

扩展IK原有词库:

分词工具	词库中词的数量	最后更新时间
ik	27.5万	2012年
mmseg	15.7万	2017年
word	64.2万	2014年
jieba	58.4万	2012年
jcesg	16.6万	2018年
sougou词库	115.2万	2019年

- 下载 ik-analyzer 分词 jar 文件,传到 solr目录/server/solr-webapp/webapp/WEB-INF/lib
- 复制6个文件到 solr目录/server/solr-webapp/webapp/WEB-INF/classes

```
# classes 目录如果不存在,需要创建该目录
mkdir /usr/local/solr-8.1.1/server/solr-webapp/webapp/WEB-INF/classes
```

```
这6个文件复制到 classes 目录下
resources/
    IKAnalyzer.cfg.xml
    ext.dic
    stopword.dic
    stopwords.txt
    ik.conf
    dynamicdic.txt
```

• 配置 managed-schema

修改 solr目录/server/solr/pd/conf/managed-schema,添加ik-analyzer分词器

```
<!-- ik分词器 -->
<fieldType name="text_ik" class="solr.TextField">
```

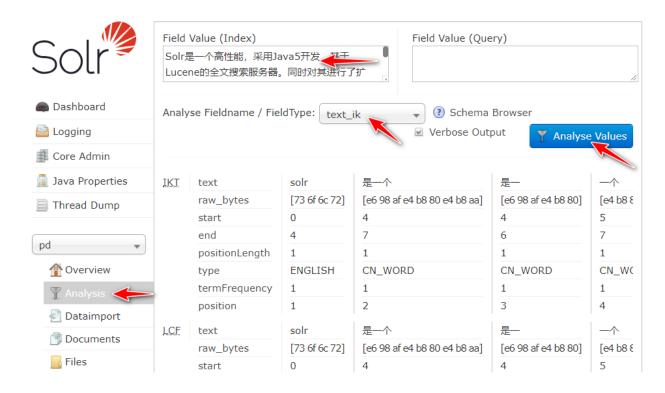
• 重启 solr 服务

```
cd /usr/local/solr-8.1.1
bin/solr restart -force
```

使用 ik-analyzer 对中文进行分词测试

填入以下文本, 选择使用 text_ik 分词器, 观察分词结果:

Solr是一个高性能,采用Java5开发,基于Lucene的全文搜索服务器。同时对其进行了扩展,提供了比Lucene 更为丰富的查询语言,同时实现了可配置、可扩展并对查询性能进行了优化,并且提供了一个完善的功能管理界面,是一款非常优秀的全文搜索引擎。



设置停止词

上传停止词配置文件到 solr目录/server/solr-webapp/webapp/WEB-INF/classes

```
stopword.dic
stopwords.txt
```

• 重启服务,观察分词结果中,停止词被忽略

bin/solr restart -force

准备 mysql 数据库数据

- 用 sqlyog 执行 pd.sql
- 授予 root 用户 跨网络访问权限 注意: 此处设置的是远程登录的 root 用户,本机登录的 root 用户密码不变

```
grant all on *.* to 'root'@'%' identified by 'root';
```

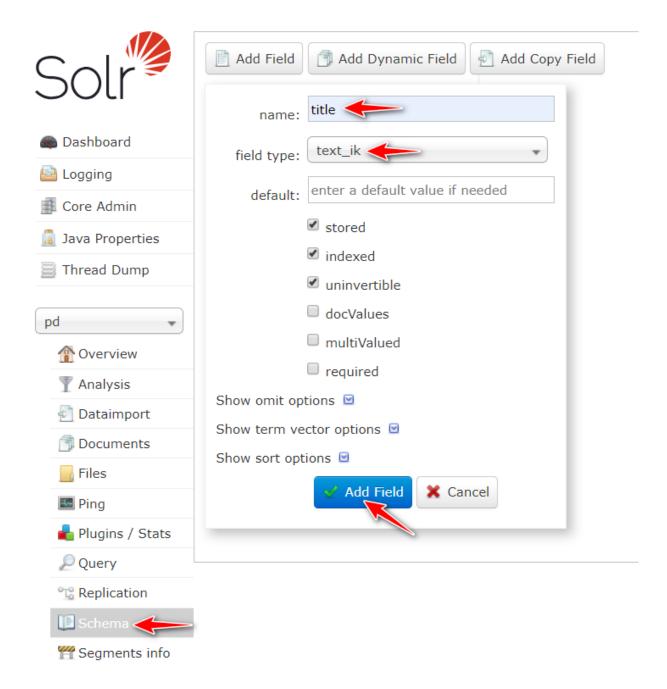
随机修改30%的商品,让商品下架,以便后面做查询测试

```
UPDATE pd_item SET STATUS=0 WHERE RAND()<0.3</pre>
```

从 mysql 导入商品数据

设置字段

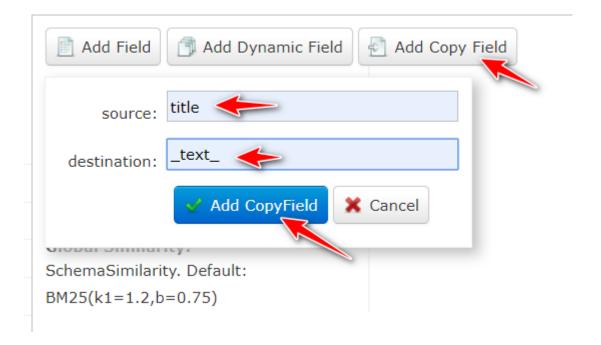
- title text_ik
- sellPoint text ik
- price plong
- barcode string
- image string
- cid plong
- status pint
- created pdate
- updated pdate



Copy Field 副本字段

查询时需要按字段查询,例如 title: 电脑,可以将多个字段的值合并到一个字段进行查询,默认查询字段 _text_

将 title 和 sellPoint 复制到 _text_ 字段



Data Import Handler 配置

• 添加 jar 文件

Data Import Handler 的 jar 文件存放在 solr目录/dist 目录下

```
solr-dataimporthandler-8.1.1.jar
solr-dataimporthandler-extras-8.1.1.jar
```

<mark>复制这两个文件和 mysql 的 jar 文件</mark>到 solr目录/server/solr-webapp/webapp/WEB-INF/lib

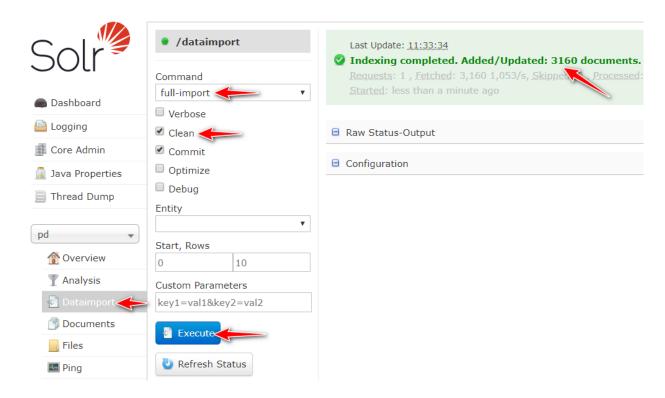
- dih-config.xml 修改 mysql 的 ip 地址,传到 solr目录/server/solr/pd/conf
- solrconfig.xml 中添加 DIH 配置

• 重启 solr

```
bin/solr restart -force
```

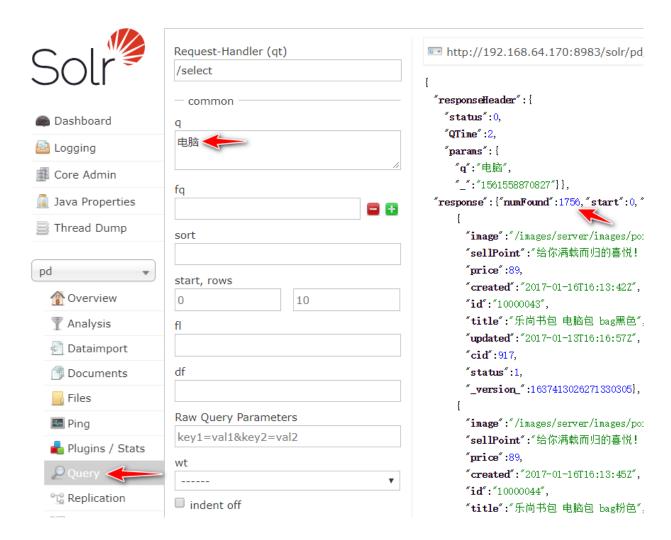
导入数据

重启 solr 后导入数据,确认导入的文档数量为 3160



查询测试

在复制字段 _text_ 中查找 电脑



在标题中查找 电脑



```
"status":0,
"QTime":25,
"params":{
    "q":"title:电脑",
    "_":"1561991032747"}},
"response":{"numFound":10, "start":0, "docs":[
    {
        "image":"/images/server/images/portal/22_LEXON_LNE6025
        "sellPoint":"给你满载而归的喜悦!",
        "price":89,
        "created":"2017-01-16T16:13:42Z",
        "id":"10000043",
        "title":"乐尚书包 电脑包 bag黑色",
        "updated":"2017-01-13T16:16:57Z",
        "a:3":017
```

用双引号查找完整词 "笔记本"

```
status .v,
                                                   "QTime" :2,
 "笔记本"
                                                   "params":{
                                                     "q":"\"笔记本\"",
                                                     "_":"1561991032747"}},
fq
                                                 "response": {"numFound":18, "start":0, "docs":[
sort
                                                       "image": "/images/mobileImage/02.png",
                                                       "sellPoint":"经典回顾! 超值特惠!",
                                                       "price":49,
start, rows
                                                       "created": "2018-11-12T16:29:47Z",
                       10
                                                       "id":"830972",
                                                       "title":"生活<mark>笔记本</mark>",
fΙ
                                                       "updated": "2015-03-08T21:28:30Z",
```

搜索 +lenovo +电脑



搜索 +lenovo -电脑



```
status:0,
    "QTime":0,
    "params":{
        "q":"+lenovo -电脑",
        "_":"1561991032747"}},
    "response":{"numFound":25,"start":0,"docs":[
        {
             "image":"/images/server/images/portal/13LenovoldeaPad310_black/collect.png",
             "sellPoint":"清仓! 仅北京,武汉仓有货! ",
             "price":5119,
             "created":"2017-01-13T16:16:57Z",
             "id":"10000020",
             "title":"联想(Lenovo)IdeaPad310低配版",
             "updated":"2017-01-13T16:16:57Z",
             "cid":163,
             "statue":1
```

统计 cid

```
✓ facet

facet.query
facet.field
cid
facet.prefix
spatial
spellcheck
 Execute Query
       title: 软法(Lenovo/丁物沟IO苹栗瓜),
      "updated":"2017-01-11T13:09:32Z",
      "cid":163,
      "status":1,
      "_version_":1637413024282181632}]
},
"facet_counts": {
  "facet_queries":{},
  "facet_fields": {
    "cid":[
      "560", 2433,
      "76",640,
      "163", 65,
      "238", 9,
      "241", 4,
      "298", 3,
      "236", 2,
      "917", 2,
      ″3″, 1,
      "925", 1]},
  "facet_ranges": {},
  "facet_intervals": {},
  "facet_heatmaps": {}}}
```

Raw Query Parameters
facet.mincount=50
wt
v
indent off
debugQuery
dismax
edismax
□ hI
✓ facet
facet.query
i dectiques y
//
facet.field
cid
facet.prefix
spatial
spellcheck

```
title: 软芯(Lenovo)()物DiO红架加),
      "updated": "2017-01-11T13:09:32Z",
      "cid":163,
      "status":1,
      "_version_":1637413024282181632}]
},
"facet_counts": {
  "facet_queries":{},
  "facet_fields": {
   "cid":[
     "560", 2433,
     "76",640,
     "163",65]},
  "facet_ranges": {},
  "facet_intervals": {},
  "facet_heatmaps": {}}}
```

价格范围

在 Raw Query Parameters 输入框中填入以下内容:

facet.range=price&facet.range.start=0&facet.range.end=10000&facet.range.gap=2000

Raw Query Parameters facet.range=price&facet.range.start=0&facet.range=price&facet.range.start=0&facet.ra			
wt			
v			
indent off			
debugQuery			
dismax			
■ e dismax			
□ hl			
✓ facet			
facet.query			
facet.field			
facet.prefix			
spatial			
spellcheck			
Execute Query			

```
title: 城湿(Lenovo/)小刺310经典版,
      "updated": "2017-01-11T13:09:32Z",
      "cid":163,
      "status":1,
      "_version_":1637413024282181632}]
},
"facet_counts": {
  "facet_queries": {},
  "facet_fields": {},
  "facet_ranges": {
    "price":{
      "counts":[
       "0", 29,
       "2000", 4,
       "4000", 36,
        "6000", 54,
       "8000",118],
      "gap":2000,
      "start":0,
      "end":10000}},
  "facet_intervals": {},
  "facet_heatmaps": {}}}
```

多字段统计

在 Raw Query Parameters 输入框中填入以下内容: facet.pivot=cid,status

Raw Query Parameters
facet.pivot=cid,status
wt
v
indent off
debugQuery
dismax
■ e dismax
□ hl
☑ facet
facet.query
facet.field
facet.prefix
spatial
spellcheck
Execute Query

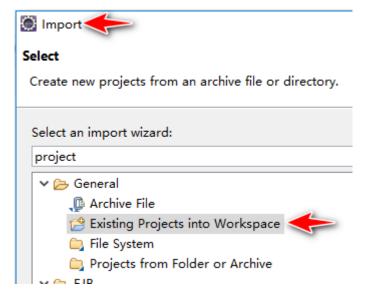
```
title: 联思(Lenovo)/小新310经典版,
      "updated": "2017-01-11T13:09:32Z",
      "cid":163,
      "status":0,
      "_version_":1637871095801446402}]
},
"facet_counts": {
  "facet_queries":{},
  "facet_fields": {},
  "facet_ranges": {},
  "facet_intervals": {},
  "facet_heatmaps": {},
  "facet_pivot": {
    "cid, status":[{
        "field": "cid",
        "value":560,
        "count":2433,
        "pivot":[{
            "field": "status",
            "value":1,
            "count":1686},
            "field": "status",
            "value":0,
            "count":747}]},
        "field": "cid",
```

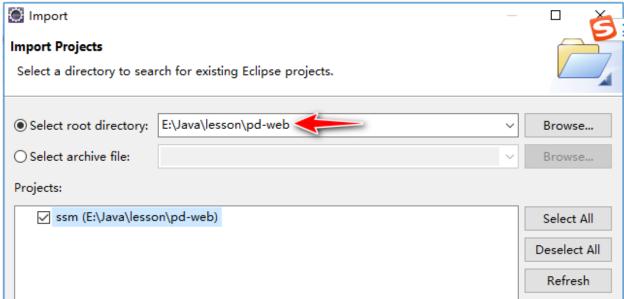
拼多商城实现商品的全文检索

修改 hosts 文件, 添加 www.pd.com 映射

```
127.0.0.1 www.pd.com
```

eclipse 导入 pd-web 项目





修改数据库连接配置

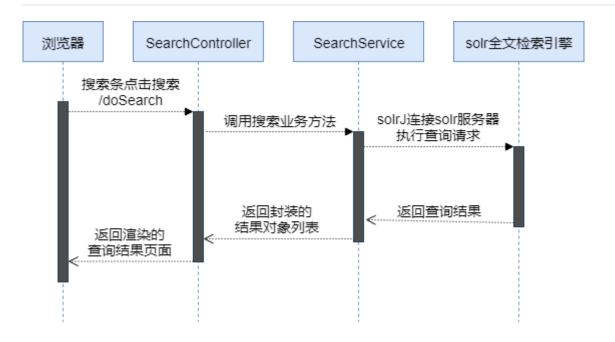
application.yml 配置文件中,修改连接配置

```
spring:
    datasource:
        type: com.alibaba.druid.pool.DruidDataSource
        driver-class-name: com.mysql.jdbc.Driver
        url: jdbc:mysql://127.0.0.1:3306/pd_store?useUnicode=true&characterEncoding=UTF-8
        username: root
        password: root
```

启动项目, 访问 www.pd.com



商品检索调用分析



pom.xml 添加 solr 和 lombok 依赖

```
<dependency>
     <groupId>org.springframework.boot</groupId>
          <artifactId>spring-boot-starter-data-solr</artifactId>
</dependency>
</dependency>
          <groupId>org.projectlombok</groupId>
```

```
<artifactId>lombok</artifactId>
</dependency>
```

application.yml 添加 solr 连接信息

```
spring:
    data:
    solr: #注意修改;p地址
    host: http://192.168.64.170:8983/solr/pd
```

Item 实体类

```
package com.pd.pojo;
import java.io.Serializable;
import org.apache.solr.client.solrj.beans.Field;
import lombok.Data;
public class Item implements Serializable {
        private static final long serialVersionUID = 1L;
        @Field("id")
        private String id;
        @Field("title")
        private String title;
        @Field("sellPoint")
        private String sellPoint;
        @Field("price")
        private Long price;
        @Field("image")
        private String image;
}
```

SearchService 业务接口

```
package com.pd.service;
import java.util.List;
import com.pd.pojo.Item;
public interface SearchService {
```

```
List<Item> findItemByKey(String key) throws Exception;
}
```

SearchServiceImpl 业务实现类

```
package com.pd.service.impl;
import java.util.List;
import org.apache.solr.client.solrj.SolrClient;
import org.apache.solr.client.solrj.SolrQuery;
import org.apache.solr.client.solrj.response.QueryResponse;
import org.springframework.beans.factory.annotation.Autowired;
import org.springframework.context.annotation.Configuration;
import org.springframework.stereotype.Service;
import com.pd.pojo.Item;
import com.pd.service.SearchService;
@Service
public class SearchServiceImpl implements SearchService {
    * SolrClient实例是在 SolrAutoConfiguration 类中创建的
    * SolrAutoConfiguration添加了@Configuration注解,
    * 是spring boot自动配置类,其中的solrClient()方法中创建了SolrClient实例
    */
   @Autowired
   private SolrClient solrClient;
   @Override
   public List<Item> findItemByKey(String key) throws Exception {
       //封装查询的关键词
       //也可以封装其他的查询参数,比如指定字段,facet设置等
       SolrQuery query = new SolrQuery(key);
       //查询前多少条数据
       query.setStart(0);
       query.setRows(20);
       //执行查询并得到查询结果
       QueryResponse qr = solrClient.query(query);
       //把查询结果转成一组商品实例
       List<Item> beans = qr.getBeans(Item.class);
       return beans;
   }
}
```

SearchController 控制器

```
package com.pd.controller;
import java.util.List;
import org.springframework.beans.factory.annotation.Autowired;
import org.springframework.stereotype.Controller;
import org.springframework.ui.Model;
import org.springframework.web.bind.annotation.GetMapping;
import com.pd.pojo.Item;
import com.pd.service.SearchService;
@Controller
public class SearchController {
   @Autowired
   private SearchService searchService;
   @GetMapping("/search/toSearch.html")
   public String search(String key, Model model) throws Exception {
        List<Item> itemList = searchService.findItemByKey(key);
        model.addAttribute("list", itemList);
        return "/search.jsp";
   }
}
```